گزارش پروژه دوم

پروژه Cliff Walking

درس: مبانی و کاربردهای هوش مصنوعی

استاد راهنما:

دکتر حسین کارشناس نجف آبادی

اعضای گروه:

علی‌اکبر احراری- 4003613001

مهرآذین مرزوق- 4003613055

پاییز 1402

فهرست

گزارش کار الگوریتم

Policy_evaluation

```
def policy_evaluation(policy):
    Vp = np.zeros(env.nS)
    Qp = np.zeros((env.nS, env.nA)) / env.nA
    converged = False
    t = 1

    while t < 1000 and not converged:
        delta = 0
        old_Vp = Vp.copy()

        for state in range(env.nS):
            if cliffs.__contains__(state):
                Vp[state] = -100
            elif state == 47:
                Vp[state] = 2000
            else:
                for action in range(env.nA):
                    ans = 0
                    for probability, state_next, rewards, complete in
env.P[state][action]:
                        ans += (1 / 2) * (rewards + gamma *
old_Vp[state_next])
                    for probability, state_next, rewards, complete in
env.P[state][(action - 1) % 4]:
                        ans += (1 / 4) * (rewards + gamma *
old_Vp[state_next])
                    for probability, state_next, rewards, complete in
env.P[state][(action + 1) % 4]:
                        ans += (1 / 4) * (rewards + gamma *
old_Vp[state_next])
                    Qp[state][action] = ans

                Vp[state] = Qp[state][int(policy[state])]

            # Calculate the change in utility value
            delta = np.max(np.abs(old_Vp - Vp[state]))

        if delta < theta:
            converged = True
        t += 1

    return Vp, Qp
```

این تابع برای تخمین ارزش valueها و q_valueها با استفاده از یک سیاست به عنوان ورودی به کار می‌رود. مراحل اجرای این تابع بدین صورت است که ابتدا ارزش وضعیت های مختلف را با 0 مقداردهی اولیه می‌کنیم. دو متغیر برای تشخیص شرایط اتمام حلقه(محدودیت تکرار و همگرایی) تعریف می‌کنیم. برای مقایسه‌کردن Vp فعلی با Vpهای جدید، از متغیر old_Vp استفاده می‌کنیم.

برای هر حالت در فضای بازی، حالات مختلفی که عامل می‌تواند در آن قرار بگیرد را بررسی می‌کنیم و بنا به آن Vp مناسب را انتخاب می‌کنیم. برای cliffها ارزش منفی صد و برای هدف اصلی، 2000 را در نظر می‌گیریم. در صورتی که عامل در حالتی دیگر باشد به صورت دیگری عمل می‌کنیم.

این بخش از کد، برای به‌روزرسانی تخمین‌های توابع ارزش وضعیت‌ها و عمل‌ها با استفاده از معادله بلمن استفاده می‌شود. این احتمالات وضعیت‌های بعدی، پاداش‌ها و اطلاعات ترانزیشن را از محیط دریافت می‌کند و بر اساس آن‌ها مقادیر توقعی تابع ارزش عمل را محاسبه می‌کند. سپس این مقادیر با وزن‌های مختلف به‌روزرسانی شده و تابع ارزش وضعیت نیز بر اساس سیاست جاری به‌روزرسانی می‌شود.

در پایان هر دور ایتریشن، میزان تغییرات در تخمین‌های تابع ارزش بررسی شده و اگر این تغییرات کمتر از یک حد مشخص (مانند theta) باشد، الگوریتم به‌صورت همگرا معلوم می‌شود و محاسبات متوقف می‌شود.

Policy_iteration

```
def policy_iteration():
    policy = np.zeros(env.nS)
    t = 1
    converged = False
    while t < 1000 and not converged:
        old_policy = policy.copy()
        Vp, Qp = policy_evaluation(policy)
        for state in range(env.nS):
            act = -1
            maxQ = -np.inf
            for action in range(env.nA):
                if Qp[state][action] > maxQ:
                    if not (state >= 0) & (state < 12) & (action == 0):
                        if not (state > 35) & (state < 48) & (action == 2):
                            if not (state % 12 == 11) & (action == 1):
                                if not (state % 12 == 0) & (action == 3):
                                    maxQ = Qp[state][action]
                                    act = action

            policy[state] = act

        delta = np.max(np.abs(policy - old_policy))
        if delta < theta:
            converged = True
        t = t + 1

    return policy
```

در این تابع به تکرار و بهینه سازی سیاست(policy) می‌پردازیم. ابتدا یک مقداردهی اولیه (مقدار 0) را در نظر می‌گیریم. برای تشخیص شرط اتمام حلقه، دو متغیر t و converged را مقداردهی اولیه می کنیم. در صورتی که تکرار از مقدار تعیین شده بگذرد و یا سیاست مورد نظر در نقطه ای همگرا شود، حلقه پایان می‌یابد. با استفاده از متغیر old_policy می‌توان همگرایی سیاست را بررسی کرد. با استفاده از تابع policy_evaluation مقادیر q_value و value ها را بدست می‌آوریم.

حال به ازای هر state در محیط بازی، بین تمامی action های ممکن به انتخاب actionی می پردازیم که مقدارQp را به حداکثر ممکن برساند. در این بین، شروطی برای حرکت عامل وجود دارند که از برخورد آن به دیواره‌ها جلوگیری می‌کنند. پس از آن action مورد نظر انتخاب شده و سیاست به روز می شود.

پس از هر بار به‌روز رسانی، بیشترین مقدار تغییرات در سیاست با استفاده از delta مورد بررسی قرار می‌گیرد و در صورتی که از مقدار theta کمتر باشد، شرط همگرایی برقرار شده است. در آخر، این تابع سیاست بهینه را بر می‌گرداند.

Main

```
# Create an environment
env = CliffWalking(render mode="human")
observation, info = env.reset(seed=30)
cliffs = list()
for i in range(10):
    a = env.cliff_positions
    cliffs.append(a)

gamma = 0.99
theta = 1e-4

Policy = policy_iteration()

print("Optimal policy:")
print(Policy)

# Define the maximum number of iterations
max_iter_number = 1000
done = False
truncated = False
reward = 0
d = 0
Action = Policy[observation]
for i in range(max_iter_number):
    print("----------------"f'{i}'"----------------")

    while True:
        # Perform the action and receive feedback from the environment
        next_state, reward, done, truncated, info = env.step(Action)
        print(f'{next_state, reward, done, truncated, info}')
        Action = Policy[next_state]
        if info['prob'] == 1.0:
            break
        if done:
            d = d + 1
            env.reset()
            break

print(d)
# Close the environment
env.close()
```

در ابتدا، محیط بازی را ایجاد می‌کنیم و حالت نمایش آن را به روی human تنظیم می‌کنیم. حالت اولیه نیز به روی reset() تنظیم می‌شود. در قسمت بعدی کد cliff ها به محیط بازی اضافه می‌شوند. در قسمت بعدی کد، دو متغیر gamma و theta را برای استفاده در توابع برنامه مقداردهی می‌کنیم. پس از بدست آوردن سیاست بهینه به وسیله تابع policy_iteration()، با محیط تعامل می‌کنیم. با استفاده از متغیر

max_iter_number حداکثر تعداد دفعات تکرار مجاز را مشخص می‌کنیم و تغییرات وضعیت را چاپ می‌کنیم.
در آخر نیز محیط را به پایان می‌رسانیم.

نمونه خروجی

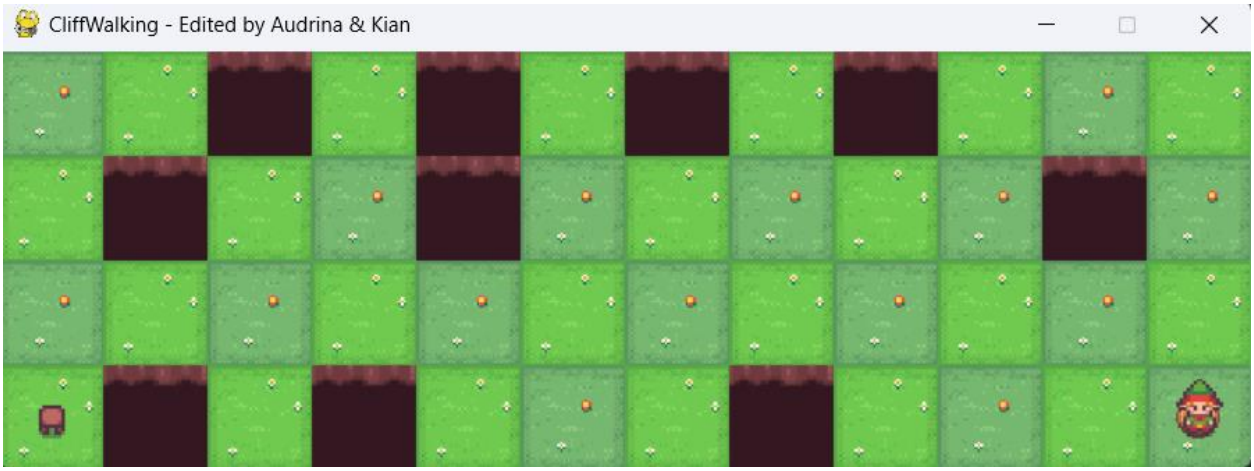


```
(8, -0.2, False, False, {'prob': 0.3333333333333333})
(7, -0.2, False, False, {'prob': 0.3333333333333333})
(8, -0.2, False, False, {'prob': 0.3333333333333333})
(9, -0.2, False, False, {'prob': 0.3333333333333333})
(8, -0.2, False, False, {'prob': 0.3333333333333333})
(9, -0.2, False, False, {'prob': 0.3333333333333333})
(8, -0.2, False, False, {'prob': 0.3333333333333333})
(20, -0.2, False, False, {'prob': 0.3333333333333333})
(21, -0.2, False, False, {'prob': 0.3333333333333333})
(22, -0.2, False, False, {'prob': 0.3333333333333333})
(34, -0.2, False, False, {'prob': 0.3333333333333333})
(35, -0.2, False, False, {'prob': 0.3333333333333333})
(47, -0.2, True, False, {'prob': 0.3333333333333333})
174

Process finished with exit code 0
```

در اینجا می‌توان دید که برنامه 174 بار توانسته به هدف برسد.

منابع

Bing AI - Search

Bard (google.com)

ChatGPT (openai.com)

Artificial Intelligence: A Modern Approach, Textbook by Peter Norvig and Stuart J. Russell